Sisteme de Operare

Administrarea perifericelor de stocare

Cristian Vidrașcu

https://profs.info.uaic.ro/~vidrascu

Cuprins

- Introducere
- Memoria secundară (discul)
  - Structura
  - Planificarea
  - Administrarea
- Gestiunea spațiului de swap
- Construirea unui disc mai bun
- Administrarea memoriei terțiare

Introducere

- Clasificarea perifericelor (d.p.d.v. funcțional)
  - **Periferice de intrare/ieșire** – pentru schimbul de informații cu mediul extern
    (e.g. tastatură, ecran, imprimantă, cititor de cartele, ș.a.)
  - **Periferice de stocare** – pentru păstrarea nevolatilă (i.e. permanentă) a informațiilor
    (e.g. disc magnetic, bandă magnetică, dischetă, CD/DVD, ș.a.)

Alte clasificări ale perifericelor /1

- Clasificarea perifericelor d.p.d.v. al modului de operare (de servire a cererilor)
  - **Periferice dedicate** – pot servi un singur proces la un moment dat
    (modelul tipic: imprimanta)
  - **Periferice partajabile** – pot servi mai multe procese simultan, în sensul concurenței aparente
    (modelul tipic: discul magnetic)

Alte clasificări ale perifericelor /2

- Clasificarea perifericelor d.p.d.v. al modului de transfer și de memorare a informației
  - **Periferice bloc**
    - memorează informațiile în *blocuri* de lungime fixă, fiecare cu adresa sa
    - blocul este unitatea de transfer între periferic și memoria internă
    - fiecare bloc poate fi citit sau scris independent de celelalte blocuri
    - blocul conține informații propriu-zise și mai poate contine, eventual, informații de control de paritate, pentru verificarea corectitudinii informației memorate
    - e.g. disc magnetic, bandă magnetică, CD/DVD, memorii flash, ș.a.
  - **Periferice caracter**

Alte clasificări ale periferice lor /3

- Clasificarea perifericelor d.p.d.v. al modului de transfer și de memorare a informației (cont.)
  - **Periferice bloc**
  - **Periferice caracter**
    - furnizează/acceptă un *flux* de octeți fără nici o structură de bloc
    - octeții din flux nu sunt adresabili
    - fiecare octet este disponibil ca și *caracter curent* numai până la apariția următorului octet
    - e.g. tastatură, mouse, ecran, imprimantă, difuzor, ș.a.

Periferice de stocare

- Clasificarea perifericelor de stocare după variația timpului de acces (t_{ij} = timpul de acces de la informația i la informația j)
  - **Periferice cu acces secvențial** – timpul de acces t_{ij} are variații foarte mari (modelul tipic: banda magnetică)
  - **Periferice cu acces complet direct** – timpul de acces t_{ij}=k, este constant (modelul tipic: memoriile bidimensionale obișnuite – RAM)
  - **Periferice cu acces direct** – timpul de acces t_{ij} are variații foarte mici (modelul tipic: discul magnetic)

Structura discului /1

- Discurile magnetice sunt adresate ca o matrice 1-dimensională (un vector) foarte mare de **blocuri logice**, unde blocul logic este cea mai mică unitate de informații ce se poate transfera (între disc și memorie)

  Indexul unui bloc în acest vector este adresa sa LBA.

- Matricea 1-dimensională de blocuri logice este mapată secvențial pe sectoarele discului

  Adresa LBA se convertește în adresa fizică (C,H,S), de către BIOS (în trecut) sau firmware-ul discului (în prezent).

Structura discului /2

- Organizarea discului
  - platane
  - piste
  - cilindri
  - sectoare
  - data

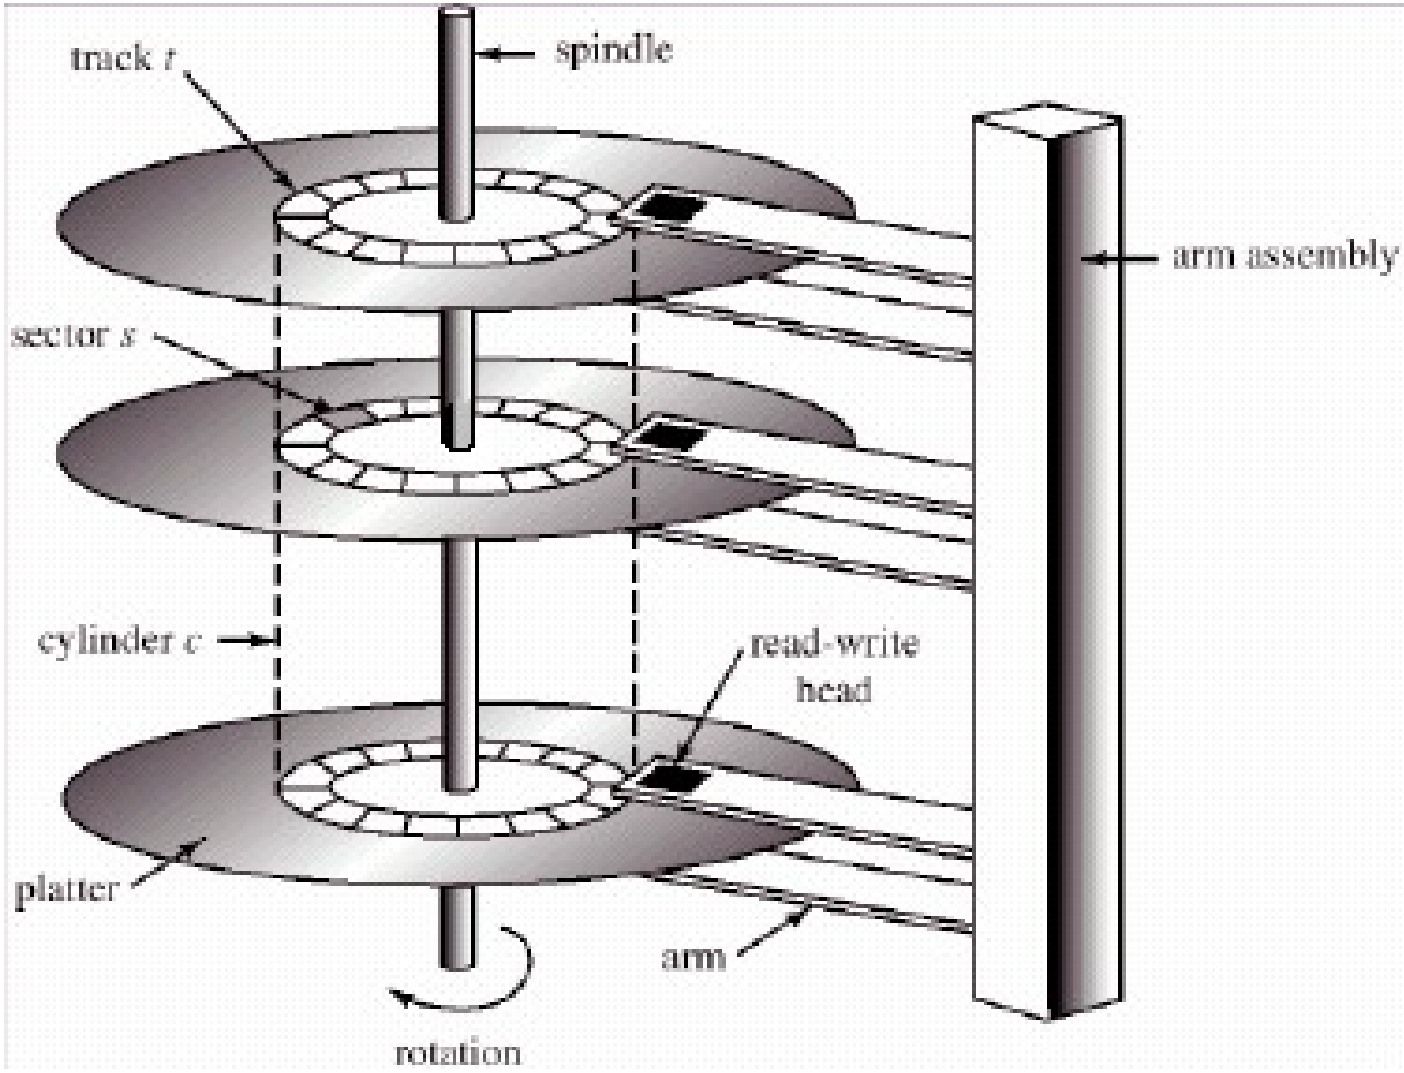

Viteza discului

- **Timpul de căutare** (*Seek time*)
  - timpul necesar pentru mișcarea (mecanică a) capului de citire-scriere până la pista specificată
- **Latența de roțatie** (*rotational Latency*)
  - timpul de așteptare necesar pentru ca sectorul specificat să ajungă prin rotație sub capul de citire-scriere
- **Timpul de transfer** (*Transfer time*)
  - timpul necesar pentru a citi datele de pe sectorul specificat
- **Timpul total de acces = S + L + T**

Probleme

- **Planificarea accesului la disc**
  - ideea este de a reorganiza cererile de acces la disc pentru a minimiza timpii de căutare (*seek*-urile)
- **Plasarea datelor pe disc** (*Layout*)
  - un mod de plasare care să minimizeze *overhead*-ul operațiilor cu discul
- **Construirea unui disc mai bun (sau a unui substituent pentru discurile actuale)**
  - exemplu: RAID

Planificarea discului /1

- Sistemul de operare este responsabil pentru utilizarea eficientă a hardware-ului
  - pentru discurile hard, aceasta înseamnă a avea un timp de acces rapid și o lățime de bandă mare
- Lățimea de bandă a discului (*disk bandwidth*) este numărul total de octeți transferați, împărțit la timpul total scurs între prima cerere de serviciu și sfârșitul ultimului transfer solicitat

Planificarea discului /2

- Timpul de acces are două componente majore:
  - *seek time* – timpul necesar discului pentru a muta capul pe cilindrul ce conține sectorul dorit
  - *rotational latency* – timpul adițional de așteptare pentru ca discul să rotească sectorul dorit sub capul de citire-scriere
  - cea de-a treia componentă, *timpul efectiv de transfer*, este o constantă specifică perifericului respectiv

- Planificarea discului urmărește minimizarea timpului de căutare, eventual și a latenței de rotație
- Ideea: schimbarea ordinii de servire a cererilor venite de la procesele concurente (cu păstrarea ordinii cererilor fiecărui proces)

Planificarea discului /3

- Algoritmi de planificare (a acceselor la disc)
  - FCFS (First Come, First Served)
  - SSTF (Shortest Seek Time First)
  - SCAN
  - C-SCAN (Circular SCAN)
  - LOOK
  - C-LOOK (Circular LOOK)

Planificarea discului /4

- Pentru exemplificările următoare ale algoritmilor de planificare, considerăm următorul scenariu:
  - un disc cu 200 cilindri (numerotați cu 0-199)
  - coada cererilor de acces (doar cilindrul ce conține sectorul dorit): 98, 183, 37, 122, 14, 124, 65, 67 (fiecare cerere provenind de la un proces distinct)
  - poziția inițială a furcii cu capetele de citire-scriere a discului: cilindrul 53

Planificarea discului /5

- **FCFS** (First Come, First Served)
  - Alg.: cererile sunt servite în ordinea sosirii
  - Figura arată o mișcare totală a capului discului de 640 cilindri

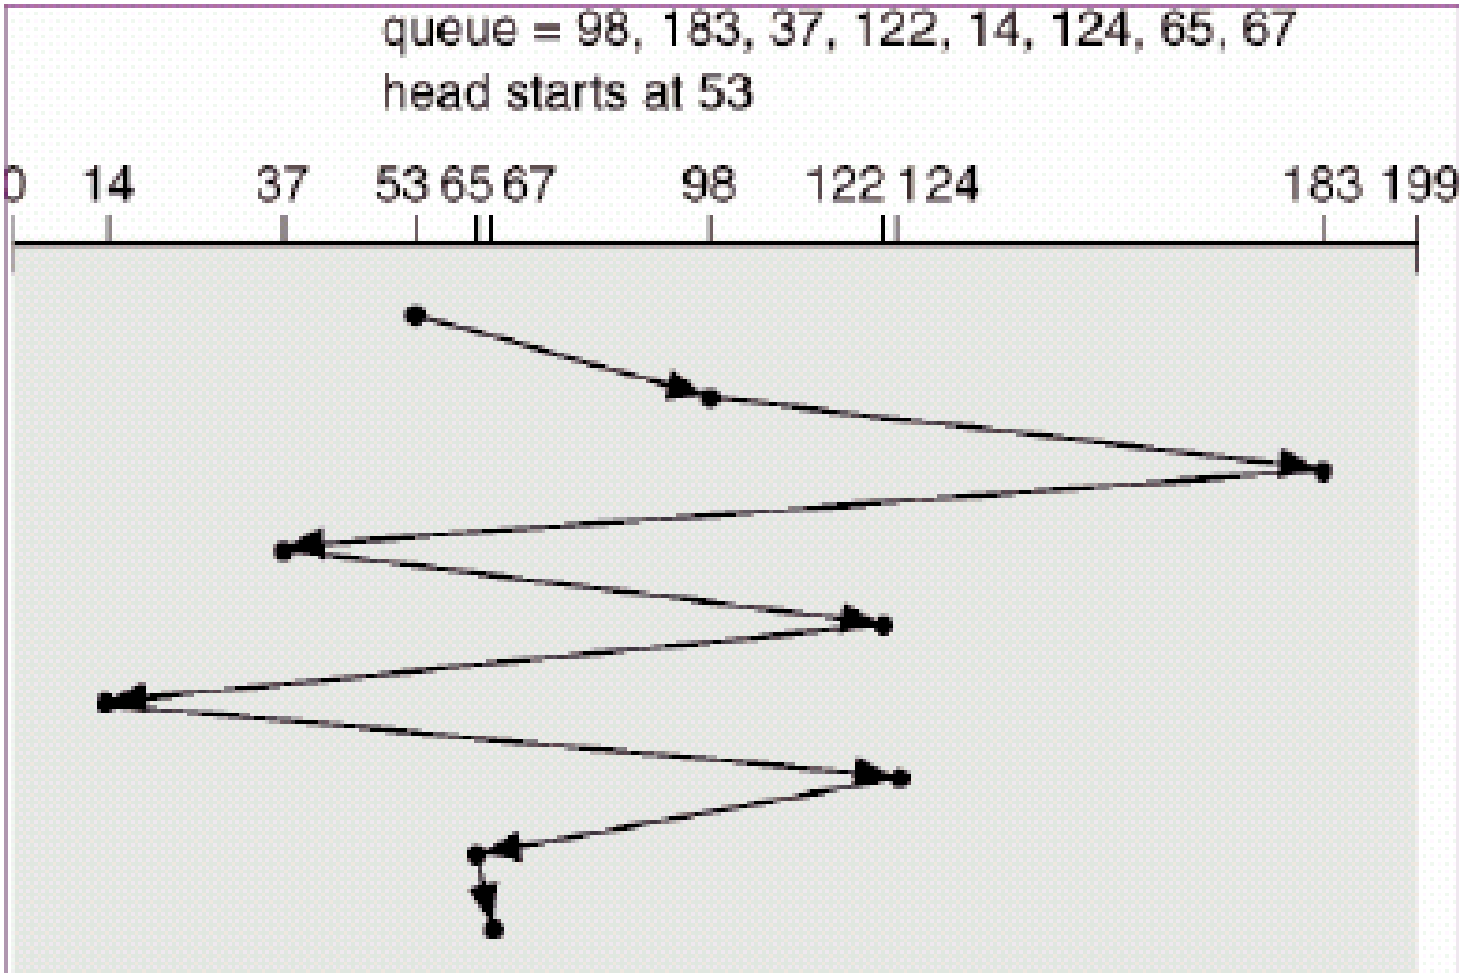

Ipoteză de lucru:
coada statică
(i.e. **toate** cererile au ajuns în coadă la momentul t=0, în ordinea specificată)

Planificarea discului /6

- **SSTF** (Shortest Seek Time First)
  - Alg.: se alege cererea cu timp de căutare minim de la poziția curentă a capului
  - Figura arată o mișcare totală a capului discului de 236 cilindri
  - Este mai eficient decât FCFS, dar nu este echitabil (poate favoriza fenomenul de *starvation:* întârzierea servirii unor cereri)

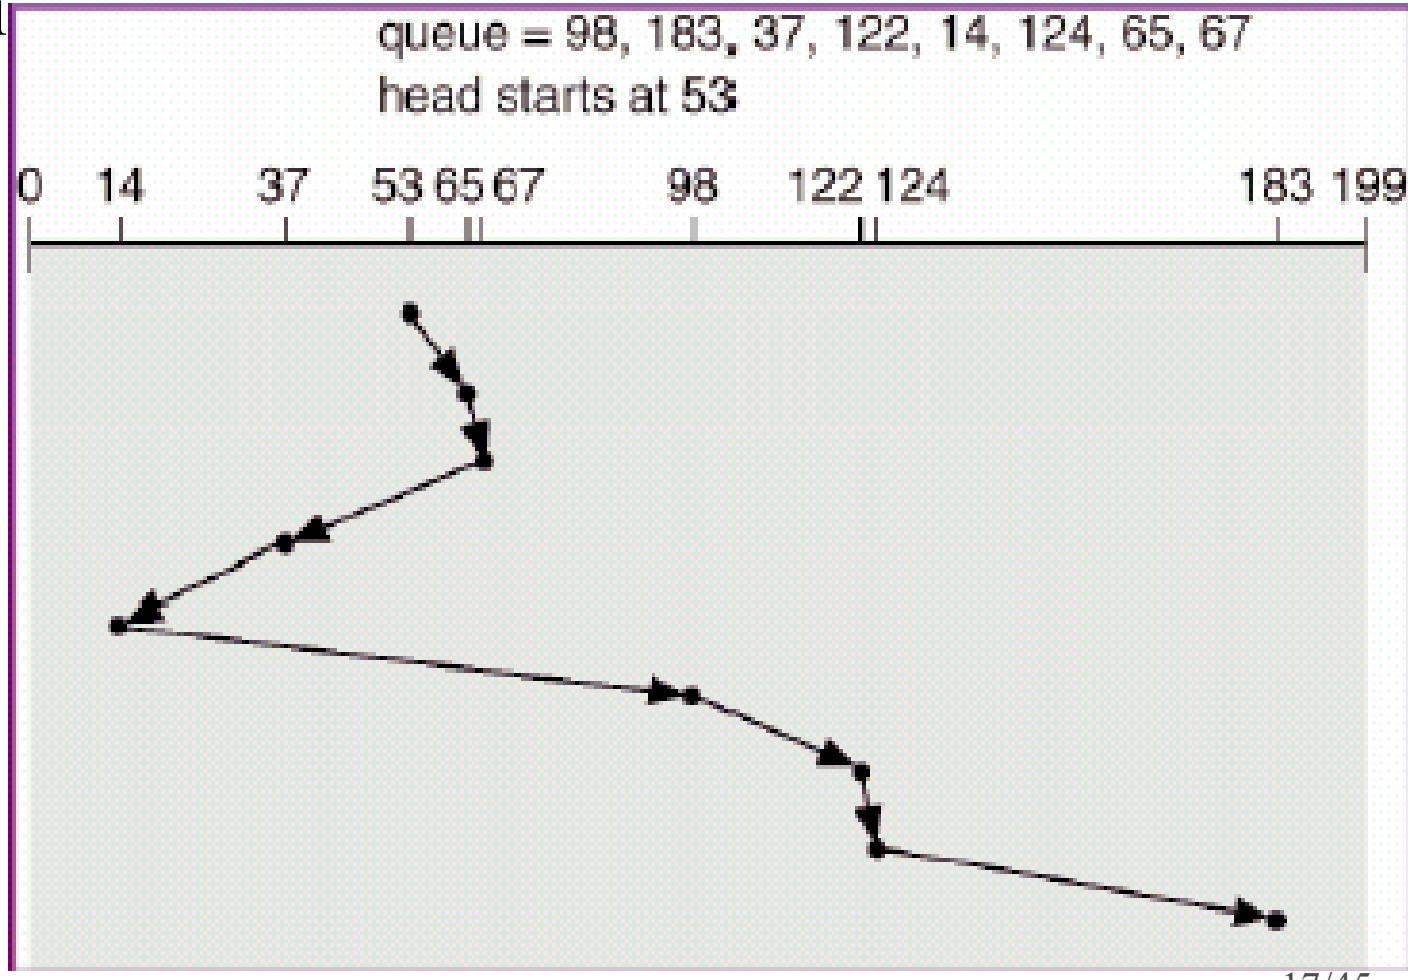

Planificarea discului /7

- **SCAN** (algoritmul elevator)
  - Alg.: brațul cu capetele R/W începe la un capăt al discului și se deplasează spre celălalt capăt, rezolvând și cererile pe parcurs, iar când ajunge la celălalt capăt, se întoarce înapoi, continuând servirea cererilor
  - Figura arată o mișcare totală a capului discului de 236 cilindri (în ipoteza că sensul inițial de deplasare era în jos. Altfel, mișcarea totală este de 331 cilindri).

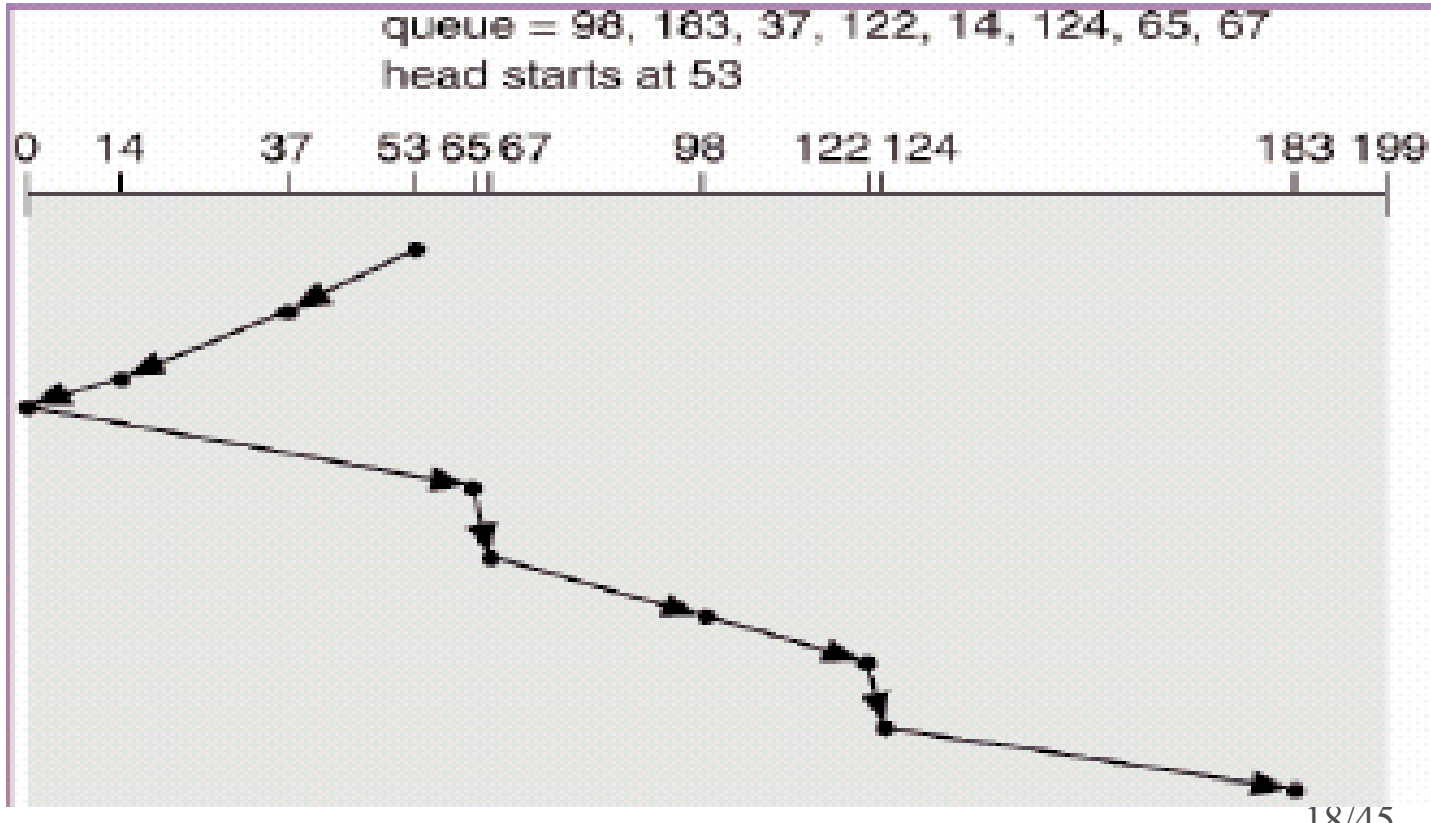

Planificarea discului /8

- **C-SCAN** (Circular SCAN)
  - Alg.: brațul cu capetele R/W începe la capătul 0 al discului și se deplasează spre celălalt capăt, rezolvând și cererile pe parcurs, iar când ajunge la celălalt capăt, se întoarce imediat (*foarte rapid*) înapoi la începutul discului, fără să servească nici o cerere pe drumul de întoarcere, și apoi reia lucrul
  - Practic, acest algoritm tratează cilindrii discului ca o listă circulară care "conectează" ultimul cilindru cu primul cilindru
  - Avantaj: furnizează un timp de așteptare (a rezolvării cererii) mai uniform decât algoritmul SCAN (la care este posibil ca o cerere să aștepte două parcurgeri ale discului până când este servită)

Planificarea discului /9

- **C-SCAN** (Circular SCAN)
  - Exemplu
  - Figura arată o mișcare totală a capului R/W a discului de 382 cilindri

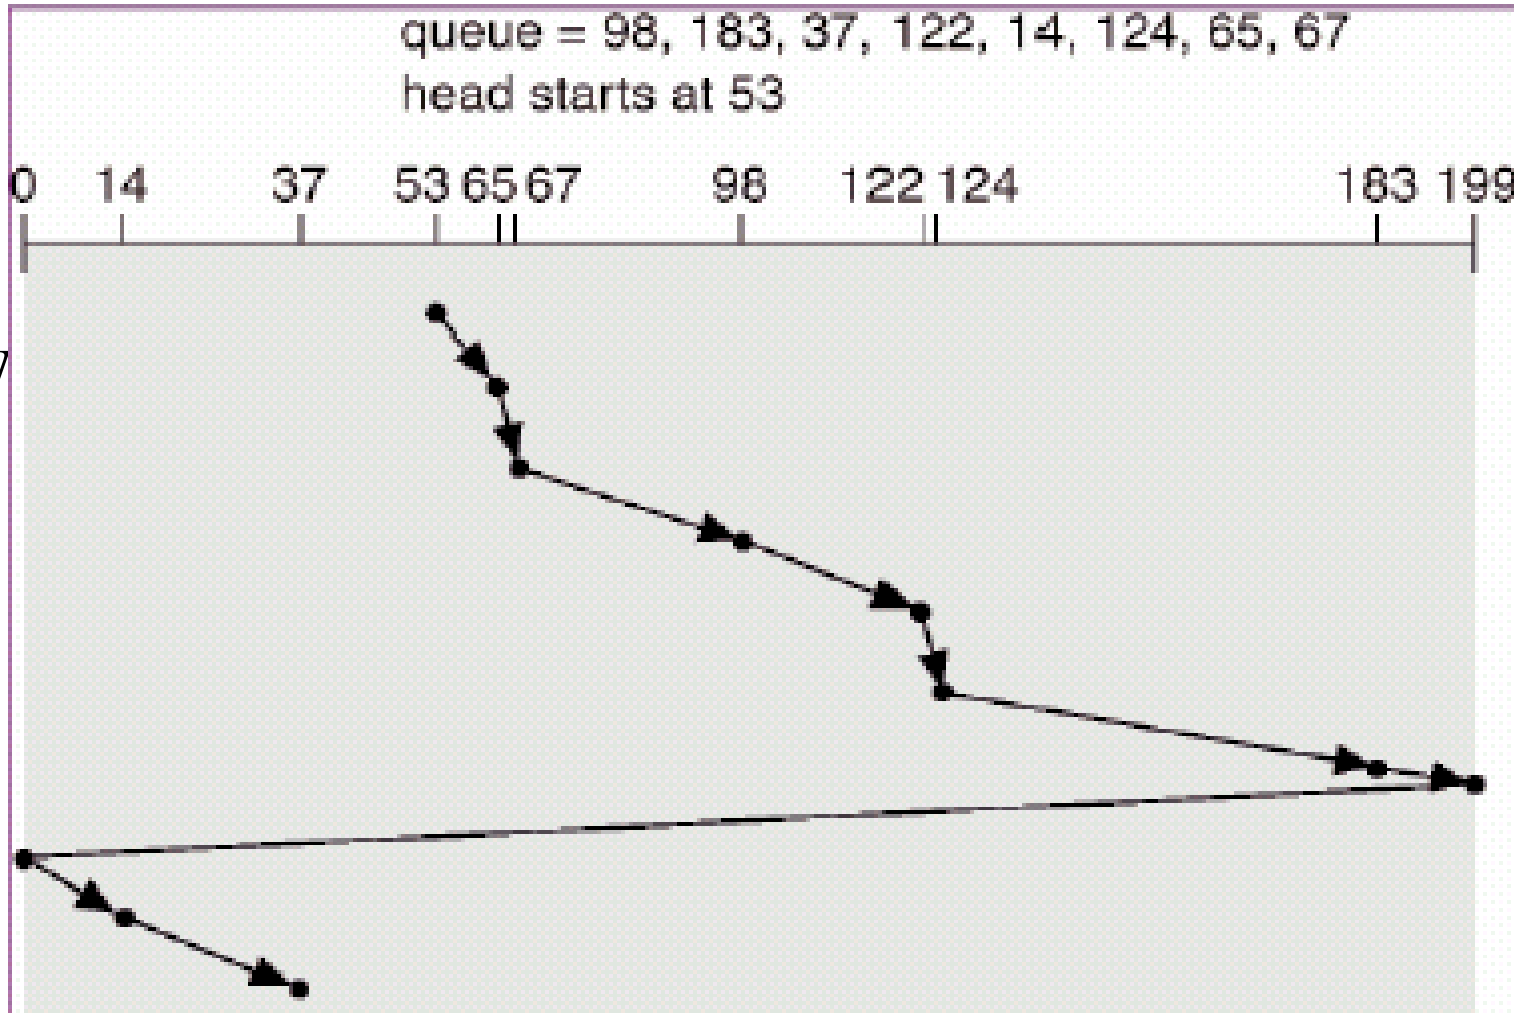

Planificarea discului /10

- **LOOK și C-LOOK** (Circular LOOK)
  - Alg.: brațul cu capetele R/W se mișcă la fel ca la algoritmii SCAN și respectiv C-SCAN, cu deosebirea că aici se mișcă doar până la ultima cerere în fiecare sens, după care inversează direcția de deplasare imediat, fără să meargă mai întâi până la capătul discului
  - Practic, LOOK/C-LOOK reprezintă o optimizare a algoritmilor SCAN/C-SCAN

Planificarea discului /11

- **LOOK și C-LOOK** (Circular LOOK)

– Exemplu

– Figura arată o mișcare totală a capului discului de 322 cilindri pentru C-LOOK (pentru LOOK ar fi 276 cilindri)

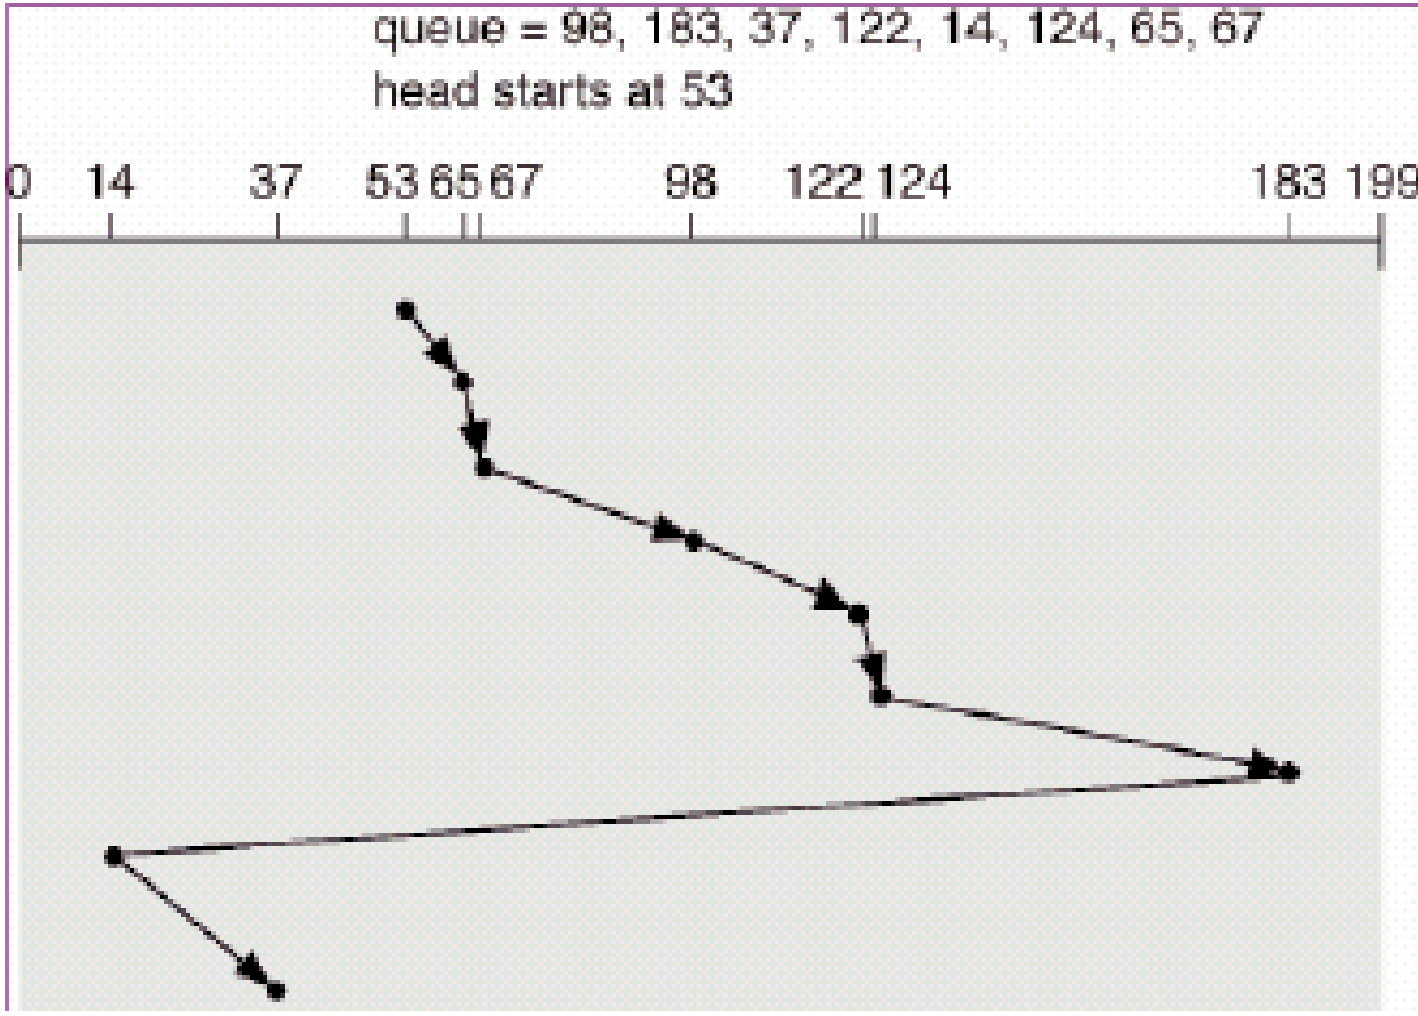

Planificarea discului /12

- **Selectarea unui alg. de planificare a discului**
  - SSTF este utilizat frecvent (dezavantaj: pericol de înfometare a unor cereri de acces la disc)
  - SCAN și C-SCAN se comportă mai bine pentru sisteme care au o încărcare mare a discului (i.e. multe operații I/O)
  - Algoritmul de planificare a discului este indicat să fie scris ca un modul separat al sistemului de operare, pentru a permite o înlocuire ușoară a sa cu un alt algoritm dacă se consideră necesar
  - Fie SSTF, fie LOOK este o alegere rezonabilă pentru algoritmul implicit de planificare a discului

Planificarea discului /13

- **Observații**
  - Performanța depinde de numărul și tipurile cererilor de acces
  - Cererile de acces pot fi influențate de metoda de alocare a fișierelor utilizată

Alt exemplu:

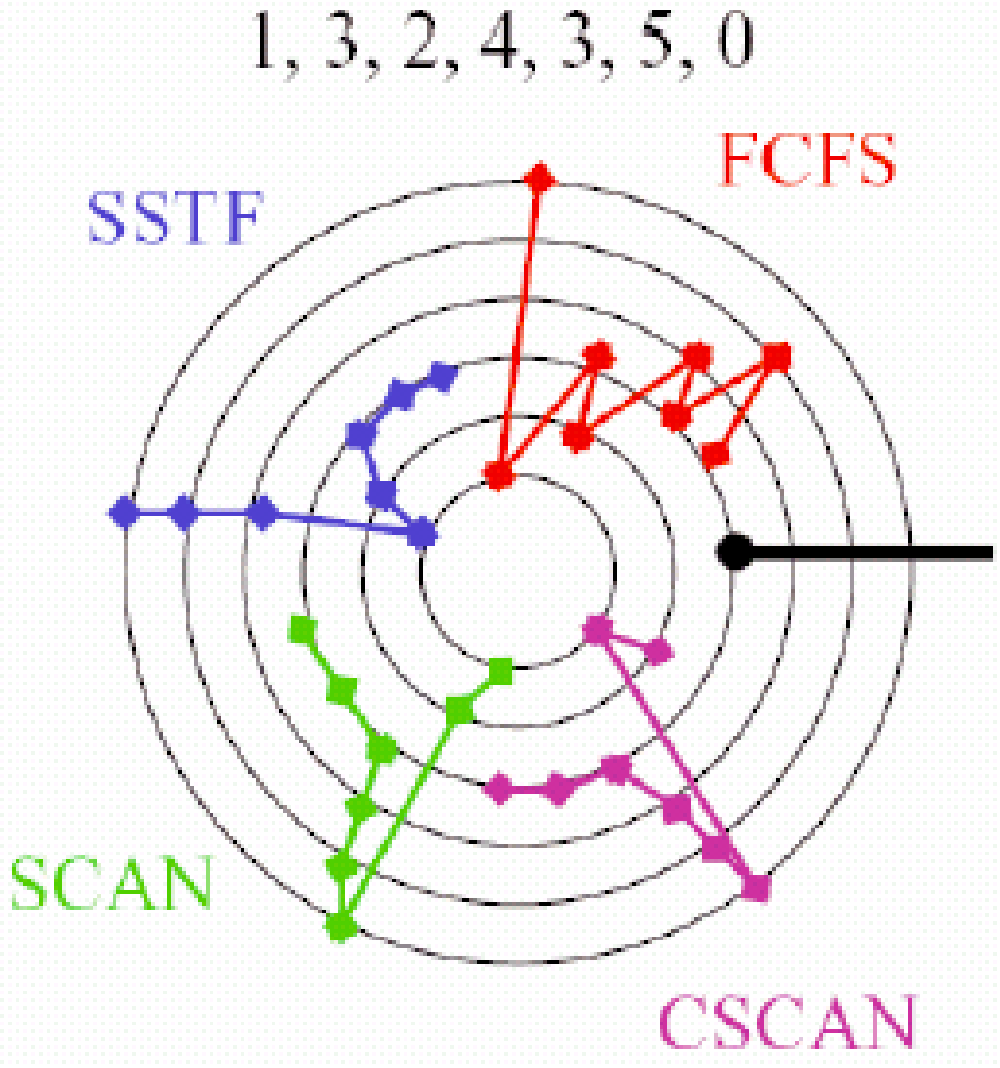

Planificarea discului /14

- **Observații** (cont.)
  - De exemplu, la alg. SSTF cele mai favorizate d.p.d.v. al timpului de acces vor fi pistele din mijloc; ca urmare se pot aloca pe aceste piste fișierele cu frecvență ridicată de utilizare, sau structura de directoare (deoarece este folosită frecvent)
  - La fel, la o recompactare (defragmentare) a discului, se pot aloca în aceste zone favorizate fișierele pentru care s-a constatat că au un grad de folosire mai ridicat

Planificarea discului /15

- **Observații** (cont.)
  - în exemplele anterioare am simplicat expunerea, presupunând coada ca fiind statică (i.e. **toate** cererile ajungeau în coadă la momentul t=0)
  - în realitate, coada este dinamică (i.e. **noi** cereri ajung în coadă pe parcursul trecerii timpului); iată un exemplu în acest sens:

Coada de cereri: 24, 45, 85 (toate ajung la t=0) ; 120, 97, 61 (toate la t=100 ms)
Se dau: *seek time* = direct proporțional cu distanța (2 ms/traversarea a 2 cilindri consecutivi); *latența de rotație*: în medie, 1 ms (pentru toate cererile); *timpul de transfer* = neglijabil.
Inițial, capul R/W este la cilindrul 50, iar sensul de deplasare este spre cilindrul cu nr. maxim.

Ordinea de servire a celor 6 cereri, folosind algoritmul LOOK, este:
1) la momentul t=0, capul R/W este poziționat la cilindrul 50;
2) la momentul t=70ms, capul ajunge la cilindrul 85, iar după 1ms începe servirea cererii respective;
3) la momentul t=151ms, capul ajunge la cilindrul 45, iar după 1ms începe servirea cererii respective;
4) la momentul t=202ms, capul ajunge la cilindrul 20, iar după 1ms începe servirea cererii respective;
5) la momentul t=285ms, capul ajunge la cilindrul 61, iar după 1ms începe servirea cererii respective;
6) la momentul t=358ms, capul ajunge la cilindrul 97, iar după 1ms începe servirea cererii respective;
7) la momentul t=405ms, capul ajunge la cilindrul 120, iar după 1ms începe servirea cererii respective.

Planificarea discului /16

- **Reducerea așteptării rotației**
  - În S.O.-urile mai pretențioase se urmărește și minimizarea latenței de rotație
  - Ideea: reordonarea servirilor cererilor existente la un moment dat pentru același cilindru – alg. SLTF (Shortest Latency Time First): *cel ce așteaptă cel mai puțin va fi servit primul*
  - Altă metodă (statică): numerotarea *întreţesută* a sectoarelor în cadrul unei piste

a) numerotare normală
b) numerotare întreţesută cu factorul 1
c) numerotare întreţesută cu factorul 2

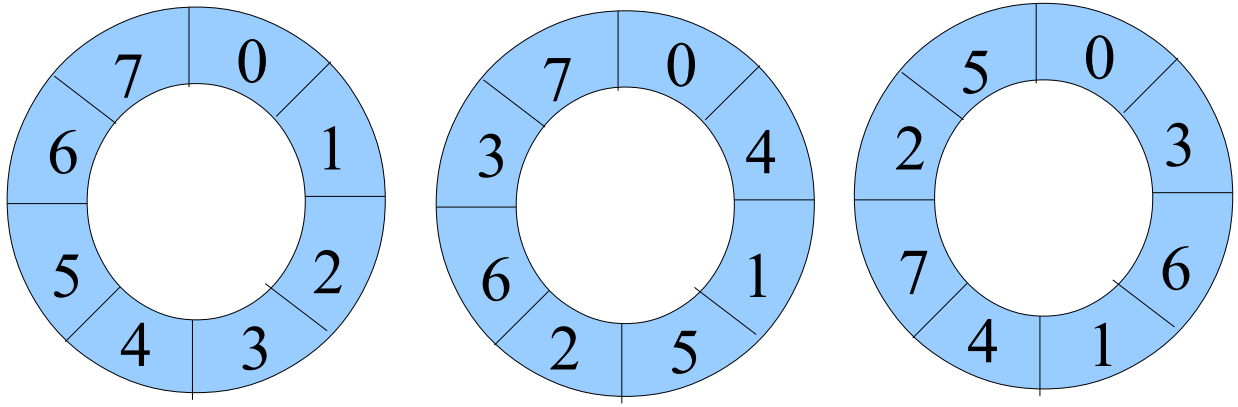

a) b) c)

Administrarea discului /1

- Formatarea fizică (formatarea *low-level*)
  - Înseamnă operația de împărțire a discului în sectoare pe care controlerul de disc le poate citi și scrie
  - Notă: în ultimii 30 de ani dimensiunea sectoarelor a fost de 512 B, dar recent au apărut discurile cu sectoare de 4 KB
- Pentru a stoca fișiere pe disc, S.O.-ul trebuie să-și înregistreze propriile structuri de date pe disc
  - Partiționarea discului într-unul sau mai multe grupuri de cilindri, numite partiții
  - Formatarea logică a unei partiții = "crearea sistemului de fișiere" rezident pe acea partiție
- Blocul de boot folosit pentru inițializarea sistemului de calcul:
  - *Bootstrap*-ul este păstrat în memoria ROM
  - programul *bootstrap loader* este păstrat pe disc în blocul de boot

Administrarea discului /2

- Schema de partiționare MBR
  - este standardul de partiționare folosit de PC-uri (BIOS)
  - un disc partiționat după această schemă va conține:
    - prima pistă este zonă rezervată (63 sectoare la discurile cu 512B/sector)
    - maxim 4 partiții primare, din care una poate fi partiție extinsă (i.e. poate conține un număr oarecare de partiții logice)
    - primul sector din cadrul primei piste se numește sectorul MBR (= Master Boot Record) și reprezintă blocul de boot, ce conține următoarele informații:
      - primii 446 octeți: conțin programul *bootstrap loader*
      - următorii 64 octeți: conțin tabela de partiții (cu informații despre poziția pe disc a celor 4 partiții primare și tipul sistemelor de fișiere stocate)
      - ultimii 2 octeți conțin întotdeauna valoarea 55AA (cu rol de semnătură)
    - restul de 62 sectoare din cadrul primei piste sunt rezervate (pentru programe de bootstrap mai mari de 446 octeți, e.g. grub stage2)

Administrarea discului /3

- Alocarea blocurilor pe disc poate adresa ambele probleme, a timpului de căutare și a latenței de rotație
- Alocarea blocurilor urmărește scopuri competitoare:
  - costul alocării
  - lățimea de bandă pentru transferul unor volume mari de date
  - eficiența operațiilor cu directoare
- **Scop**: reducerea mișcării brațului (cu capetele R/W ale) discului și a *overhead*-ului datorat *seek*-urilor
  - metrica utilizată: lățimea de bandă utilizată
- Metode de gestiune a blocurilor bad (e.g. sector sparing)

Administrarea discului /4

- O abordare posibilă pentru alocarea blocurilor:
  - Grupurile de cilindri utilizate de FFS (Fast File System)
    - FFS definește grupurile de cilindri drept unitatea de localitate a discului și factorizează localitatea în posibilități de alegere pentru alocare
    - **Strategia**: plasarea blocurilor de date "înrudite" în același grup de cilindri ori de câte ori acest lucru este posibil

Gestiunea spațiului de swap /1

- **Spațiul de swap**
  - Memoria virtuală utilizează spațiu pe disc drept o extensie a memoriei principale
- Spațiul de swap poate fi localizat:
  - într-un fișier (sau mai multe) din sistemul normal de fișiere (e.g. Windows)
  - pe o partiție (sau un disc) separată (e.g. UNIX/Linux)

Gestiunea spațiului de swap /2

- **Exemplu:**
  - UNIX BSD 4.3 îi alocă spațiu de swap la începutul execuției procesului
  - spațiul alocat conține:
    segmentul de text (programul) și segmentul de date

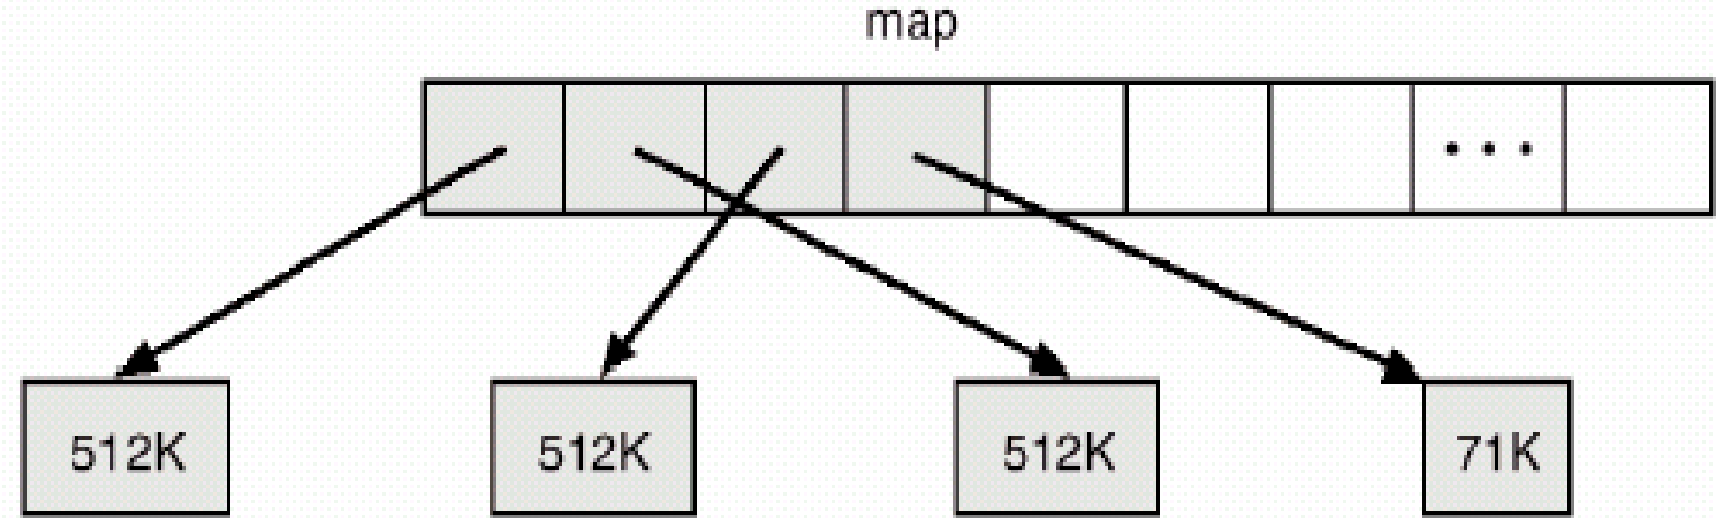

Construirea unui disc mai bun /1

- **De ce?**
  - "Mai bun" a însemnat de obicei o densitate mai mare pentru producătorii de discuri – discurile mai mari sunt mai bune
  - I/O *bottleneck* – discrepanța de viteză cauzată de faptul că procesoarele devin mai rapide mult mai repede decât discurile
  - O idee este de a folosi paralelismul mai multor discuri
    - **Împrăștierea datelor** (*data striping*) pe mai multe discuri
    - Probleme de siguranță a păstrării datelor – introducerea tehnicilor de **redundanţă** a datelor

Construirea unui disc mai bun /2

- **Soluție**
  - RAID (Redundant Array of Independent Disks)
    - Discurile multiple asigură **siguranţa** păstrării datelor prin **redundanţa** datelor
    - Discurile RAID se clasifică în 7 nivele RAID
    - *Striping*-ul utilizează un grup de discuri ca o singură unitate de stocare
    - Schemele RAID îmbunătățesc performanța și siguranța sistemului de stocare prin stocarea redundantă a datelor
      - prin tehnica oglindirii (*mirroring* sau *shadowing*) se păstrează un duplicat al fiecărui disc
      - tehnica *block interleaved parity* folosește mult mai puțină informație pentru redundanță

Un disc mai bun /3

- **Nivelele RAID**

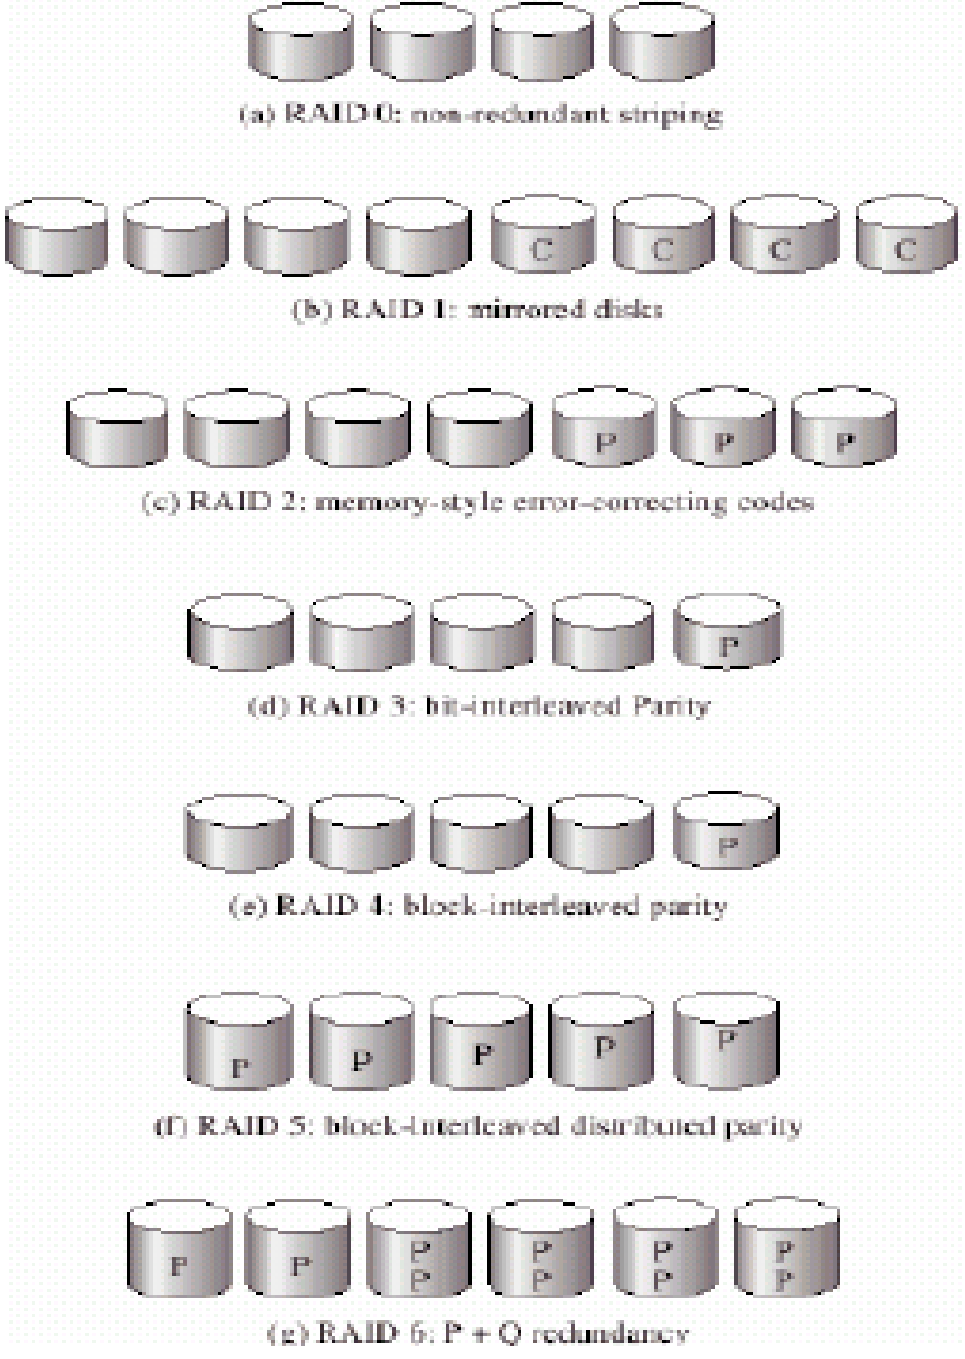

Construirea unui disc mai bun /4

- **Nivelele RAID**
  - Nivelul 0: fără redundanță, doar *striping*
  - Nivelul 1: discuri oglindite
  - Nivelul 2: coduri Hamming corectoare de erori
  - Nivelul 3: un disc de paritate la fiecare grup, *bit-interleaved*
  - Nivelul 4: citiri/scrieri independente, *block-interleaved*
  - Nivelul 5: datele/informația de paritate sunt împrăștiate pe toate discurile (mărește accesul concurent)
  - Nivelul 6: rezistă la mai mult de o singură eroare de disc

Construirea unui disc mai bun /5

- **RAID (0+1)**

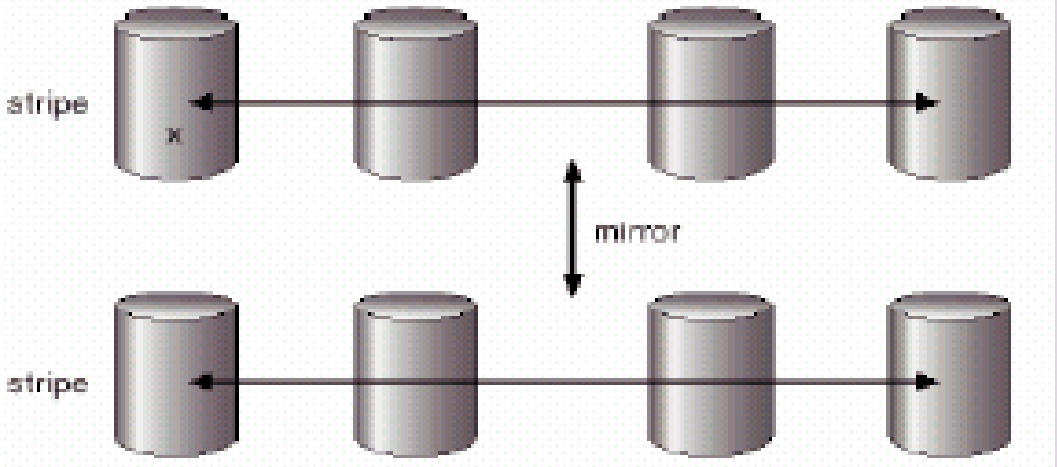

a) RAID 0 + 1 with a single disk failure

- **RAID (1+0)**

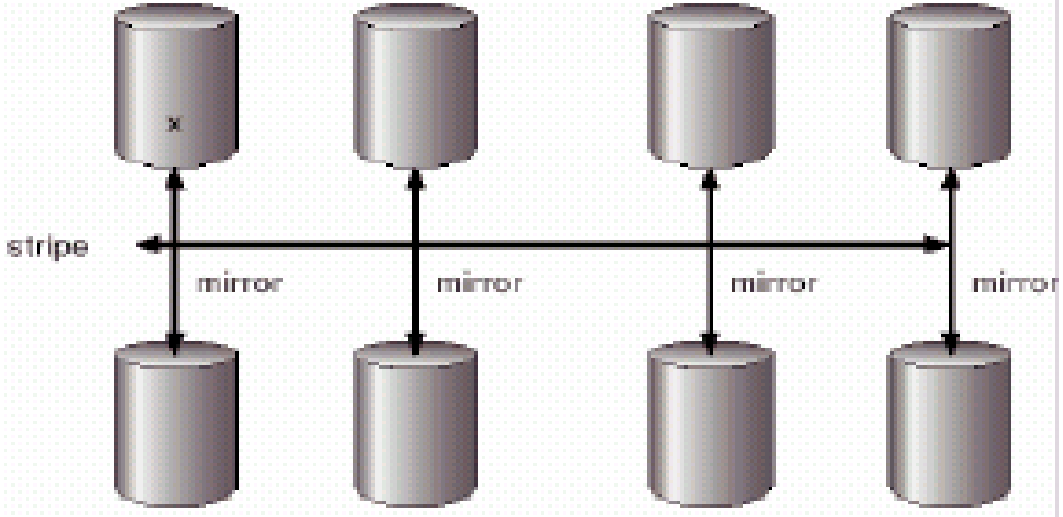

b) RAID 1 + 0 with a single disk failure

Construirea unui disc mai bun /6

- **RAID – nivelele 2 și 3**

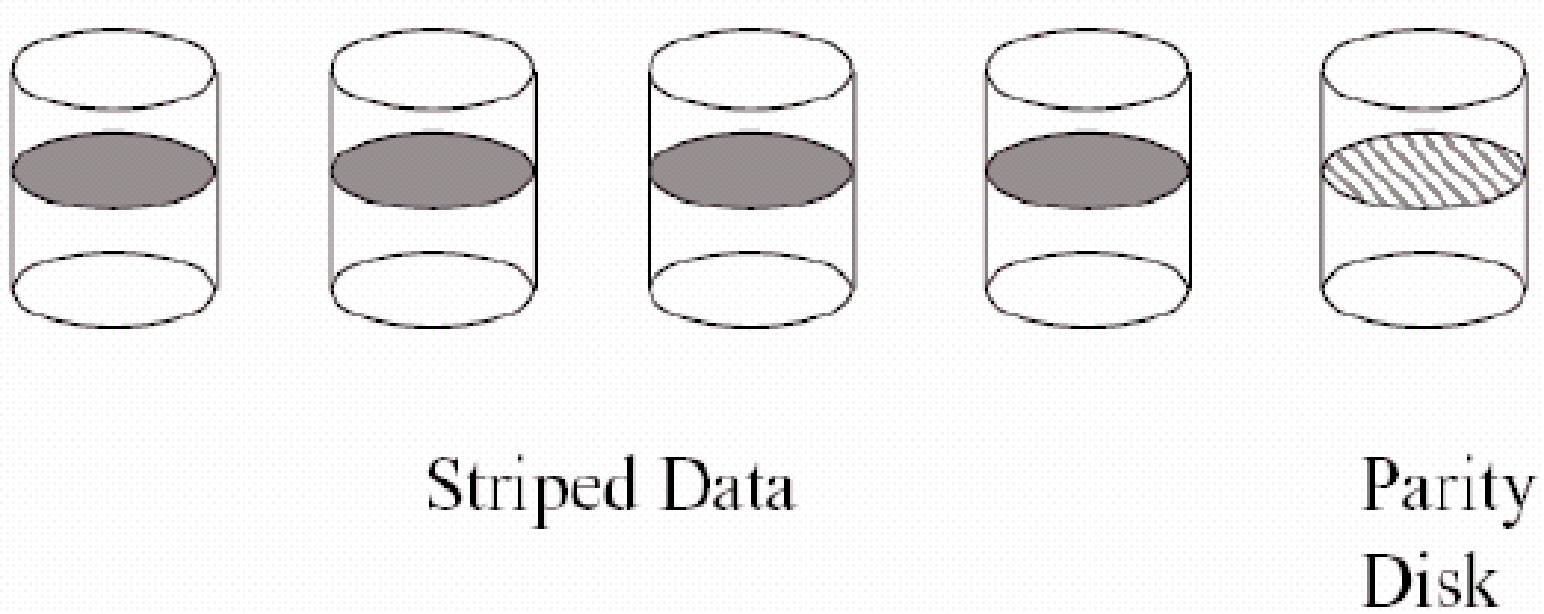

Construirea unui disc mai bun /7

- **RAID : Paritatea**
  - paritate bit/block-interleaved pentru toleranță la erori
  - exemplu: stocarea valorii binare 1010

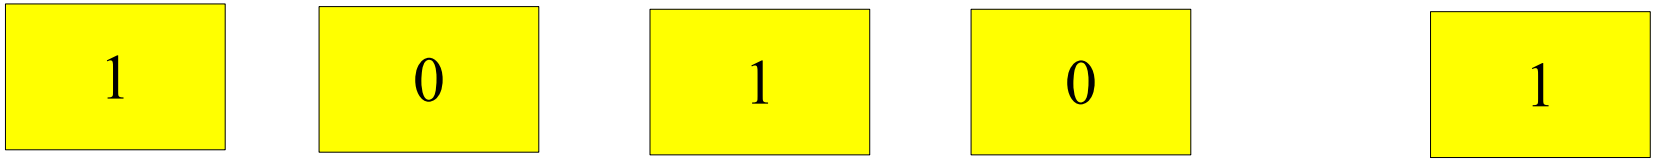

– Tolerează eroarea unui singur disc, întrucât eroarea este fie pe discul de paritate, fie pe unul dintre discurile de date
– Citește data, iar în caz de eroare, citește informatia de paritate și corectează data
– Scrierea necesită în plus și actualizarea informației de paritate

Construirea unui disc mai bun /8

- **RAID – implementare hardware:**
  – controlerul RAID este o placă hardware (fie discretă, fie este integrată în northbridge, la unele modele de plăci de bază)
  – plus un set de discuri, cu caracteristici specifice nivelului RAID dorit
- **RAID – implementare software:**
  – controlerul RAID este implementat prin software
  – plus un set de discuri, cu caracteristici specifice nivelului RAID dorit

Exemple de implementări software:
– un *device* virtual, la nivelul nucleului SO: md (Linux), softraid (OpenBSD)
– some logical *volume managers*: LVM (Linux), discuri dinamice create cu unealta Disk Management (Windows), sau tehnologia Storage Spaces (Win8/Win10)
– o componentă la nivelul *file-system*-ului: ZFS, btrfs (vezi cursul precedent)
– un nivel/o aplicație deasupra *file-system*-ului: SnapRAID, FlexRAID, etc.

Implementări la nivel de firmware+drivere specializate: e.g. Intel Matrix RAID

Referință: https://en.wikipedia.org/wiki/RAID#Implementations

Administrarea memoriei terțiare /1

- Caracteristica definitorie a memoriei terțiare: costul scăzut
- În general, memoria terțiară este construită folosind medii de stocare de tip *removable* (e.g. dischete, CD/DVD-uri, memorii flash)
- Sunt disponibile și alte tipuri ...

Administrarea memoriei terțiare /2

- **Discuri *removable*:**
  - Discul floppy (discheta) – un disc subțire și flexibil, acoperit cu un strat de material magnetic și închis într-o carcasă protectivă de plastic
  - Discul magneto-optic – înregistrează datele pe un platan rigid acoperit cu un strat de material magnetic
  - Discul optic – nu utilizează magnetismul; se folosesc materiale speciale ce sunt modificate de raza laser
- **Medii WORM** (Write Once, Read Many times)
  - Exemple: CD-uri, DVD-uri
- **Benzi magnetice**
- **Memorii flash** (tehnologie NAND)
  - Exemple: *stick*-uri USB, *disk*-uri SSD, *card*-uri de memorie (în diverse formate: CF, SD, MMC, ș.a.)

Bibliografie

- **Bibliografie obligatorie**

  capitolele despre *administrarea perifericelor de stocare* din

  – Silberschatz : "*Operating System Concepts*"
  (cap.11 din [OSCE8])

  sau

  – Tanenbaum : "*Modern Operating Systems*"
  (cap.5, §5.4 din [MOS3])

Sumar

- Introducere
- Memoria secundară (discul)
  - Structura
  - Planificarea
  - Administrarea
- Gestiunea spațiului de swap
- Construirea unui disc mai bun
- Administrarea memoriei terțiare

Întrebări ?